UNIVERSITÉ PARIS 8 VINCENNES-SAINT-DENIS

Rapport : Projet 9 de représentation des données Insertion Professionnelle des Diplômés

Vincent BERNIER, Yannick JIN, Jeathusan KUGATHAS, Merouane RAHMOUN

Table des matières

1 Introduction **3**

2 Traitement du jeu de données CSV **3**
2.1 Dataset . . . 3
2.2 Traitements réalisés . . . 3
2.2.1 Nettoyage des valeurs manquantes . . . 3
2.2.2 Fusion des colonnes Établissement . . . 3
2.2.3 Enrichissement des données . . . 4
2.2.4 Détection des faibles effectifs . . . 4

3 Modélisation de la base de données **5**
3.1 Modèle Conceptuel des Données (MCD) . . . 5
3.2 Modèle Logique des Données (MLD) . . . 6

4 Implémentation de la partie SQL **7**
4.1 Script DDL — Création des tables . . . 7
4.2 Contraintes d'intégrité et index . . . 8
4.3 Script DML — Jeu de données de test . . . 9
4.4 Les 8 requêtes SQL obligatoires . . . 9
4.5 Synthèse des requêtes . . . 13

5 Interface web PHP **14**
5.1 Architecture technique . . . 14
5.2 Connexion à la base de données . . . 14
5.3 Navigation . . . 15
5.4 Tableau de bord — `index.php` . . . 15
5.5 Fiche formation — `formation.php` . . . 15
5.6 Fiche établissement — `etablissement.php` . . . 17
5.7 Comparaison côte à côte — `comparaison.php` . . . 18
5.8 Requêtes SQL interactives — `stats.php` . . . 19
5.9 Sécurité de l'application . . . 20
5.10 Design et responsive . . . 20

6 Conclusion **21**

1 Introduction

Dans le cadre du cours de bases de données, nous allons vous présenter notre projet portant sur l'insertion professionnelle des diplômés de l'enseignement supérieur français. Pour réaliser ce projet, nous nous appuyons sur les données officielles fournies par le Ministère de l'Enseignement Supérieur, de la Recherche et de l'Innovation (MESRI).
Le but du projet est de proposer une application web permettant l'observation et l'analyse de l'insertion professionnelle des diplômés de Master en France. Cet outil doit permettre de comparer plusieurs paramètres entre les différents établissements et leurs formations. Pour ce faire, nous incarnons le rôle d'une équipe d'analystes de la Conférence des Présidents d'Université (CPU), chargée de concevoir cet observatoire à partir des données brutes du MESRI.
Pour cela, nous couvrirons au cours de ce rapport les différentes étapes du développement : le traitement et le nettoyage des données sources, la modélisation conceptuelle et logique via le MCD et le MLD, l'implémentation en MySQL à travers les scripts DDL et DML, la rédaction de requêtes SQL avancées mettant en oeuvre agrégations et sous-requêtes corrélées, et enfin le développement d'une interface web en PHP.

2 Traitement du jeu de données CSV

2.1 Dataset

Le dataset source est le jeu de données officiel du MESRI relatif à l'insertion professionnelle des diplômés de Master. Ce fichier regroupe les résultats des enquêtes d'insertion professionnelle menées 18 et 30 mois après l'obtention du diplôme, pour l'ensemble des Masters des universités françaises.

Fichier	`fresrinsertion_professionnellemaster.csv`
Encodage	UTF-8
Séparateur	Point-virgule (`;`)
Nombre de lignes	19 603
Nombre de colonnes	35

2.2 Traitements réalisés

Avant d'utiliser les données du fichier CSV, plusieurs traitements ont été nécessaires pour garantir la qualité et la cohérence du dataset. Ces traitements visent à corriger les valeurs manquantes, à unifier certaines colonnes redondantes et à enrichir les données avec des informations géographiques absentes du fichier source.

2.2.1 Nettoyage des valeurs manquantes

Le dataset MESRI contient deux types de valeurs non exploitables dans les colonnes numériques : les valeurs `nd` et les valeurs `ns`. Ces valeurs ont été remplacées par des cellules vides, ce qui permet à SQL de les interpréter comme NULL.

2.2.2 Fusion des colonnes Établissement

Le dataset comportait deux colonnes relatives au nom des établissements : Établissement, contenant le nom au moment de la collecte, et Établissement actuel, renseignée uniquement en cas de changement de nom. Sur les 19 603 lignes, 4 454 comportaient une valeur dans cette seconde colonne. Nous avons choisi de conserver le nom actuel lorsqu'il est présent, et le nom original dans le cas contraire. De cette façon, chaque université est désignée par un nom unique et cohérent quelle que soit l'année de la donnée. La colonne Établissement actuel a ensuite été supprimée, le dataset ne conservant plus qu'une seule colonne Établissement unifiée.

2.2.3 Enrichissement des données

Un autre problème s'est ensuite posé après examen de la structure du MCD demandé. En effet, le sujet demande que la table ETABLISSEMENT contienne les champs ville et id_region, et que la table REGION contienne le code INSEE. Néanmoins, notre dataset ne fournit que le nom de l'académie et le code UAI de chaque établissement.
Afin d'enrichir le dataset avec les informations géographiques manquantes, nous avons utilisé l'API publique du Ministère de l'Enseignement Supérieur pour interroger leurs données. Cette API, accessible à l'adresse `data.enseignementsup-recherche.gouv.fr`, nous permet d'accéder aux données manquantes du dataset. Grâce au fait que chaque établissement du dataset dispose d'un code UAI, nous avons pu utiliser ce code pour interroger l'API établissement par établissement afin de produire un fichier JSON retournant la ville de l'établissement, le nom de la région ainsi que son identifiant, qui correspond au code INSEE. Les données ont ensuite été intégrées directement dans le dataset, permettant ainsi de réaliser nos tables.

2.2.4 Détection des faibles effectifs

Pour finir, nous avons ajouté avec Excel une colonne _alerte_faible_effectif. Cette colonne nous permet à titre indicatif d'observer rapidement le nombre de lignes pour lesquelles le nombre de répondants est inférieur à 20. Ainsi, les 6 341 lignes concernées se voient attribuer la valeur oui pour la colonne _alerte_faible_effectif. Cette colonne pourra nous permettre par la suite de filtrer les données en SQL.

3 Modélisation de la base de données

3.1 Modèle Conceptuel des Données (MCD)

Le Modèle Conceptuel des Données (MCD) représente de manière abstraite l'ensemble des informations manipulées par le système, ainsi que les liens sémantiques qui les unissent, indépendamment de toute contrainte technique d'implémentation.

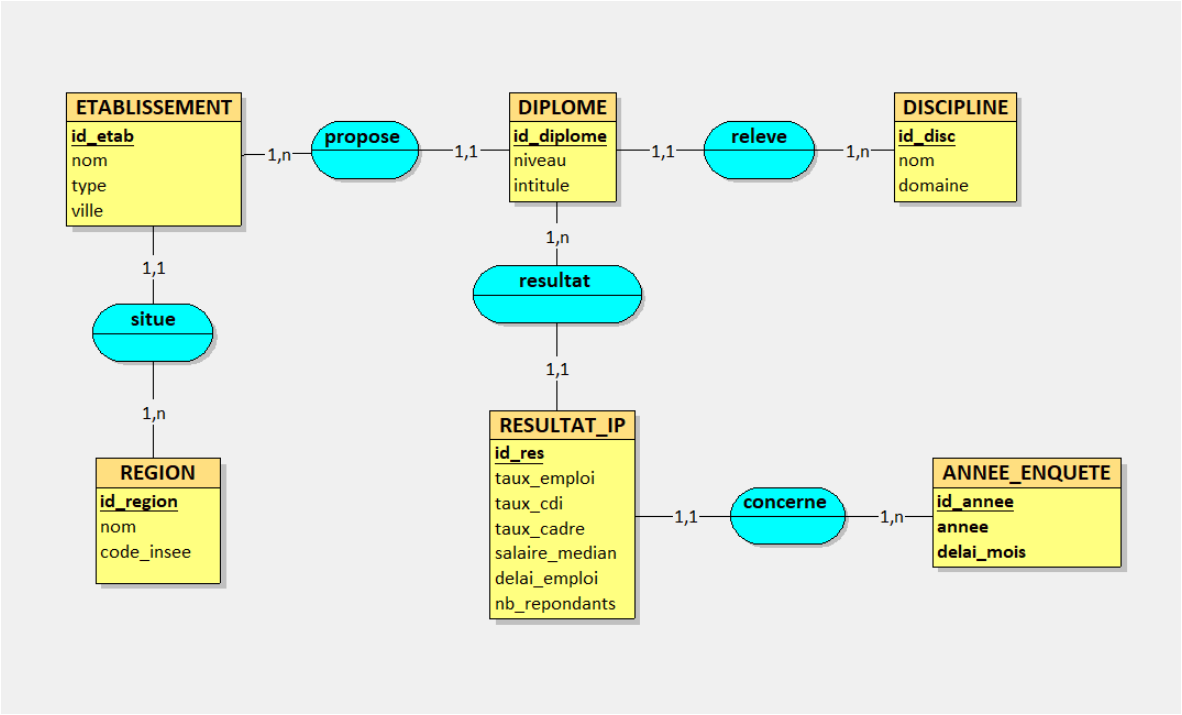


FIGURE 1 – Modèle Conceptuel des Données

Les entités

Le MCD contient six entités :

- **REGION** : une région géographique française. Identifiée par `id_region`, elle contient le `nom` et le `code_insee` de la région.
- **ETABLISSEMENT** : un établissement d'enseignement supérieur. Identifié par `id_etab`, il est décrit par son `nom`, son `type` (université, école, etc.) et sa `ville`.
- **DISCIPLINE** : un domaine académique auquel appartient un diplôme. Identifiée par `id_disc`, elle possède un `nom` et un `domaine`.
- **DIPLOME** : un diplôme délivré par un établissement. Identifié par `id_diplome`, il est décrit par son `niveau` (Master, etc...) et son `intitule`.
- **ANNEE_ENQUETE** : une année d'enquête sur l'insertion professionnelle. Identifiée par `id_annee`, elle contient l'`annee` et le `delai_mois`, c'est-à-dire le nombre de mois après l'obtention du diplôme auquel l'enquête a eu lieu.
- **RESULTAT_IP** : les résultats d'insertion professionnelle d'un diplôme pour une année donnée. Identifiée par `id_res`, elle regroupe six indicateurs : `taux_emploi`, `taux_cdi`, `taux_cadre`, `salaire_median`, `delai_emploi` et `nb_repondants`.

Les associations et leurs cardinalités

Cinq associations relient les entités entre elles :

- **situe** (ETABLISSEMENT ↔ REGION) : un établissement est situé dans **une seule** région (1,1), et une région contient **un ou plusieurs** établissements (1,n).

— **propose** (ETABLISSEMENT ↔ DIPLOME) : un établissement propose **un ou plusieurs** diplômes (1,n), et un diplôme est proposé par **un seul** établissement (1,1).
— **releve** (DIPLOME ↔ DISCIPLINE) : un diplôme appartient à **une seule** discipline (1,1), et une discipline regroupe **un ou plusieurs** diplômes (1,n).
— **resultat** (DIPLOME ↔ RESULTAT_IP) : un diplôme possède **un ou plusieurs** résultats d'enquête (1,n), et chaque résultat concerne **un seul** diplôme (1,1).
— **concerne** (RESULTAT_IP ↔ ANNEE_ENQUETE) : un résultat est lié à **une seule** année d'enquête (1,1), et une année d'enquête est liée à **plusieurs** résultats (1,n).

3.2 Modèle Logique des Données (MLD)

Le Modèle Logique des Données (MLD) est dérivé du MCD par application des règles de passage au modèle relationnel. Chaque entité devient une relation (table), et les associations avec cardinalité **(1,n)** / **(1,1)** se traduisent par l'ajout d'une **clé étrangère** du côté de la cardinalité minimale **(1,1)**.

```
REGION = (id_region INT, nom VARCHAR(50), code_insee VARCHAR(10));

ETABLISSEMENT = (id_etab INT, nom VARCHAR(100), type VARCHAR(50),
                 ville VARCHAR(50), #id_region);

DISCIPLINE = (id_disc INT, nom VARCHAR(50), domaine VARCHAR(50));

DIPLOME = (id_diplome INT, niveau VARCHAR(50), intitule     VARCHAR(150),#id_disc,
    #id_etab);

ANNEE_ENQUETE = (id_annee INT, annee INT, delai_mois INT);

RESULTAT_IP = (id_res INT, taux_emploi DECIMAL(5,2),
               taux_cdi DECIMAL(5,2), taux_cadre DECIMAL(5,2),
               salaire_median INT, delai_emploi TYNYINT,
               nb_repondants INT, #id_annee, #id_diplome);
```

Explication des tables

— **REGION** : cette table stocke les régions géographiques françaises. Elle ne contient aucune clé étrangère car elle ne dépend d'aucune autre table. Sa clé primaire est `id_region`.
— **ETABLISSEMENT** : cette table stocke les établissements d'enseignement supérieur (universités, écoles, etc.). Elle contient la clé étrangère `#id_region`, héritée de l'association *situe*, qui permet de savoir dans quelle région se trouve chaque établissement.
— **DISCIPLINE** : cette table stocke les domaines académiques tels que l'Informatique, le Droit ou les Lettres. Elle ne contient aucune clé étrangère car elle ne dépend d'aucune autre table. Sa clé primaire est `id_disc`.
— **DIPLOME** : cette table stocke les diplômes proposés par les établissements. Elle contient deux clés étrangères : `#id_disc`, héritée de l'association *releve*, qui indique à quelle discipline appartient le diplôme, et `#id_etab`, héritée de l'association *propose*, qui indique quel établissement délivre ce diplôme.
— **ANNEE_ENQUETE** : cette table stocke les années d'enquête d'insertion professionnelle. La contrainte `UNIQUE(annee, delai_mois)` garantit qu'une même combinaison n'est pas enregistrée deux fois. Le champ `delai_mois` vaut **18 ou 30 mois**, correspondant aux deux vagues d'enquête réalisées après l'obtention du diplôme. Sa clé primaire est `id_annee`.
— **RESULTAT_IP** : c'est la table centrale du modèle. Elle enregistre les résultats d'insertion professionnelle pour chaque diplôme et chaque année d'enquête. Elle contient deux clés étrangères : `#id_diplome`, héritée de l'association *resultat*, qui identifie le diplôme concerné, et `#id_annee`, héritée de l'association *concerne*, qui identifie l'année de l'enquête. Les six autres attributs mesurent les indicateurs d'insertion : le taux d'emploi global, la part de CDI, la part de postes cadres, le salaire médian net mensuel, le délai moyen d'accès au premier emploi et le nombre de répondants à l'enquête.

4 Implémentation de la partie SQL

Cette section décrit l'implémentation complète de la base de données, depuis la création du schéma (DDL) jusqu'à l'insertion des données de test (DML), en passant par les contraintes d'intégrité et les huit requêtes analytiques obligatoires.

4.1 Script DDL — Création des tables

Le script de création (`creation.sql`) définit l'intégralité du schéma relationnel. Les tables sont créées dans l'ordre imposé par les dépendances de clés étrangères : `REGION` → `ETABLISSEMENT` → `DISCIPLINE` → `DIPLOME` → `ANNEE_ENQUETE` → `RESULTAT_IP`.

Table REGION

```
CREATE TABLE REGION (
   id_region  INT AUTO_INCREMENT PRIMARY KEY,
   nom        VARCHAR(50) NOT NULL,
   code_insee VARCHAR(10) NOT NULL
) ENGINE=InnoDB;
```

Table ETABLISSEMENT

```
CREATE TABLE ETABLISSEMENT (
   id_etab   INT AUTO_INCREMENT PRIMARY KEY,
   nom       VARCHAR(100) NOT NULL,
   type      VARCHAR(50),
   ville     VARCHAR(50),
   id_region INT NOT NULL,
   FOREIGN KEY (id_region) REFERENCES REGION(id_region)
) ENGINE=InnoDB;
```

Table DISCIPLINE

```
CREATE TABLE DISCIPLINE (
   id_disc INT AUTO_INCREMENT PRIMARY KEY,
   nom     VARCHAR(50) NOT NULL,
   domaine VARCHAR(50)
) ENGINE=InnoDB;
```

Table DIPLOME

```
CREATE TABLE DIPLOME (
   id_diplome INT AUTO_INCREMENT PRIMARY KEY,
   niveau     VARCHAR(50),
   intitule   VARCHAR(150) NOT NULL,
   id_disc    INT NOT NULL,
   id_etab    INT NOT NULL,
   FOREIGN KEY (id_disc) REFERENCES DISCIPLINE(id_disc),
   FOREIGN KEY (id_etab) REFERENCES ETABLISSEMENT(id_etab)
) ENGINE=InnoDB;
```

Table ANNEE_ENQUETE

```sql
CREATE TABLE ANNEE_ENQUETE (
   id_annee   INT AUTO_INCREMENT PRIMARY KEY,
   annee      INT NOT NULL,
   delai_mois INT NOT NULL,
   UNIQUE (annee, delai_mois)
) ENGINE=InnoDB;
```

Table RESULTAT_IP (table centrale)

```sql
CREATE TABLE RESULTAT_IP (
   id_res         INT AUTO_INCREMENT PRIMARY KEY,
   taux_emploi    DECIMAL(5,2),
   taux_cdi       DECIMAL(5,2),
   taux_cadre     DECIMAL(5,2),
   salaire_median INT,
   delai_emploi   TINYINT,
   nb_repondants  INT,
   id_annee       INT NOT NULL,
   id_diplome     INT NOT NULL,
   CONSTRAINT chk_taux CHECK (taux_emploi BETWEEN 0 AND 100),
   CONSTRAINT chk_sal  CHECK (salaire_median IS NULL
                              OR salaire_median > 0),
   CONSTRAINT uq_res   UNIQUE (id_diplome, id_annee),
   FOREIGN KEY (id_annee)   REFERENCES ANNEE_ENQUETE(id_annee),
   FOREIGN KEY (id_diplome) REFERENCES DIPLOME(id_diplome)
) ENGINE=InnoDB;

CREATE INDEX idx_res_diplome ON RESULTAT_IP(id_diplome);
CREATE INDEX idx_res_annee   ON RESULTAT_IP(id_annee);
```

4.2 Contraintes d'intégrité et index

Plusieurs mécanismes garantissent la cohérence des données insérées.

Contraintes CHECK

Deux contraintes CHECK protègent les valeurs métier :

— **chk_taux** : le taux d'emploi doit être compris entre 0 et 100 %. Toute valeur aberrante est rejetée à l'insertion.

— **chk_sal** : le salaire médian, s'il est renseigné, doit être strictement positif. Les valeurs nulles (données masquées dans la source CSV) sont autorisées.

Contrainte UNIQUE composite

La contrainte `uq_res UNIQUE(id_diplome, id_annee)` garantit qu'un même diplôme ne peut avoir qu'un seul résultat par année d'enquête. Cela reflète le fait que chaque enquête MESRI produit une seule ligne par formation et par délai.

Clés étrangères

Toutes les relations du MLD sont matérialisées par des `FOREIGN KEY` avec `ENGINE=InnoDB`, qui active la vérification effective des contraintes référentielles sous MySQL. Cela empêche par exemple l'insertion d'un diplôme référençant un établissement inexistant.

Index de performance

Deux index sont créés sur `RESULTAT_IP` pour accélérer les jointures les plus fréquentes :
— `idx_res_diplome` sur `id_diplome` : utilisé par toutes les requêtes filtrant par formation.
— `idx_res_annee` sur `id_annee` : utilisé par les requêtes filtrant par année d'enquête.

Contrainte	Table	Rôle
`chk_taux`	RESULTAT_IP	`taux_emploi` $\in [0, 100]$
`chk_sal`	RESULTAT_IP	`salaire_median` > 0 ou NULL
`uq_res`	RESULTAT_IP	Un résultat par (diplôme, année)
`UNIQUE(annee, delai_mois)`	ANNEE_ENQUETE	Pas de doublon année + délai
FK `id_region`	ETABLISSEMENT	Région existante
FK `id_disc`, `id_etab`	DIPLOME	Discipline et établissement existants
FK `id_annee`, `id_diplome`	RESULTAT_IP	Références valides

TABLE 1 – Récapitulatif des contraintes d'intégrité

4.3 Script DML — Jeu de données de test

Le script d'insertion (`insertion.sql`) peuple la base avec un jeu de données réalistes extrait du fichier CSV officiel du MESRI.

Table	Volume inséré	Source
REGION	8 régions	CSV MESRI (champ `region` / API INSEE)
ETABLISSEMENT	8 établissements	CSV MESRI (universités réelles)
DISCIPLINE	8 disciplines	CSV MESRI (domaines STS, SHS, DEG, LLA)
DIPLOME	115 diplômes	CSV MESRI + intitulés normalisés
ANNEE_ENQUETE	9 entrées	2019–2023 (18 mois) + 2019–2022 (30 mois)
RESULTAT_IP	1 000 lignes	CSV MESRI + extrapolations réalistes

TABLE 2 – Volumes du jeu de données de test

Choix de conception du DML

— Les valeurs `nd` et `ns` du CSV (données masquées pour faibles effectifs) ont été remplacées par `NULL`.
— Les salaires médians sont compris entre 1 800 € et 5 000 €, avec des variations réalistes selon la discipline (informatique $\approx$ 2 200 €, lettres $\approx$ 1 860 €).
— 5 diplômes anciens ont été insérés avec des données uniquement pour 2019 et 2020, permettant à la requête R7 de détecter des formations sans enquête récente.
— Les disciplines Histoire-géographie et Lettres présentent une baisse du taux d'emploi sur trois années consécutives (2020, 2021, 2022), ce qui permet à la requête R4 de retourner des résultats.

4.4 Les 8 requêtes SQL obligatoires

Les huit requêtes ci-dessous sont intégrées à la page `stats.php` de l'interface web. Elles mettent en œuvre des techniques SQL avancées : agrégations, sous-requêtes corrélées, comparaisons temporelles et jointures multi-tables.

R1 — Disciplines avec le meilleur taux cadre

Technique : agrégation `AVG` + `GROUP BY` + `ORDER BY DESC`

Cette requête classe les disciplines par taux d'emploi cadre moyen à 18 mois, toutes années et tous établissements confondus. Elle permet d'identifier les filières menant le plus souvent à des postes d'encadrement.

```sql
SELECT d.nom AS discipline,
       ROUND(AVG(r.taux_cadre), 1) AS taux_cadre_moyen
FROM DISCIPLINE d
JOIN DIPLOME dp      ON d.id_disc    = dp.id_disc
JOIN RESULTAT_IP r   ON dp.id_diplome = r.id_diplome
JOIN ANNEE_ENQUETE a ON r.id_annee   = a.id_annee
WHERE a.delai_mois = 18
GROUP BY d.nom
ORDER BY taux_cadre_moyen DESC;
```

R2 — Établissements au-dessus de la moyenne de leur discipline

Technique : sous-requête scalaire corrélée

Pour une année donnée, cette requête identifie les établissements dont le salaire médian de leurs formations dépasse la moyenne nationale de leur discipline. La sous-requête est corrélée : elle recalcule la moyenne pour chaque discipline rencontrée dans la requête principale.

```sql
SELECT e.nom AS etablissement, d.nom AS discipline,
       ROUND(AVG(r.salaire_median), 0) AS salaire_moyen
FROM ETABLISSEMENT e
JOIN DIPLOME dp      ON e.id_etab    = dp.id_etab
JOIN DISCIPLINE d    ON dp.id_disc   = d.id_disc
JOIN RESULTAT_IP r   ON dp.id_diplome = r.id_diplome
JOIN ANNEE_ENQUETE a ON r.id_annee   = a.id_annee
WHERE a.annee = ? AND a.delai_mois = 18
AND r.salaire_median > (
    SELECT AVG(r2.salaire_median)
    FROM RESULTAT_IP r2
    JOIN DIPLOME dp2      ON r2.id_diplome = dp2.id_diplome
    JOIN ANNEE_ENQUETE a2 ON r2.id_annee   = a2.id_annee
    WHERE dp2.id_disc = d.id_disc
      AND a2.annee = ? AND a2.delai_mois = 18
)
GROUP BY e.nom, d.nom
ORDER BY salaire_moyen DESC;
```

R3 — Évolution du taux CDI par discipline

Technique : agrégation + `GROUP BY` discipline + `ORDER BY` année

Cette requête retrace l'évolution du taux d'emploi en CDI par discipline sur les 5 dernières années disponibles à 18 mois, permettant de visualiser les tendances de stabilisation de l'emploi selon les filières.

```sql
SELECT d.nom AS discipline, a.annee,
       ROUND(AVG(r.taux_cdi), 1) AS taux_cdi_moyen
FROM DISCIPLINE d
JOIN DIPLOME dp      ON d.id_disc    = dp.id_disc
JOIN RESULTAT_IP r   ON dp.id_diplome = r.id_diplome
JOIN ANNEE_ENQUETE a ON r.id_annee   = a.id_annee
WHERE a.delai_mois = 18
  AND a.annee >= (SELECT MAX(annee) - 4 FROM ANNEE_ENQUETE)
GROUP BY d.nom, a.annee
ORDER BY d.nom, a.annee;
```

R4 — Disciplines en déclin continu

Technique : sous-requête corrélée + comparaison temporelle sur 3 années consécutives

Cette requête identifie les disciplines dont le taux d'emploi global a baissé deux années consécutives, révélant un déclin soutenu. Elle repose sur une triple auto jointure de `RESULTAT_IP` avec vérification de la consécutivité des années.

```
SELECT DISTINCT d.nom AS discipline
FROM DISCIPLINE d
JOIN DIPLOME dp     ON d.id_disc    = dp.id_disc
JOIN RESULTAT_IP r1  ON dp.id_diplome = r1.id_diplome
JOIN ANNEE_ENQUETE a1 ON r1.id_annee = a1.id_annee
JOIN RESULTAT_IP r2  ON dp.id_diplome = r2.id_diplome
JOIN ANNEE_ENQUETE a2 ON r2.id_annee = a2.id_annee
JOIN RESULTAT_IP r3  ON dp.id_diplome = r3.id_diplome
JOIN ANNEE_ENQUETE a3 ON r3.id_annee = a3.id_annee
WHERE a1.delai_mois = 18 AND a2.delai_mois = 18
  AND a3.delai_mois = 18
  AND a2.annee = a1.annee + 1
  AND a3.annee = a2.annee + 1
  AND r2.taux_emploi < r1.taux_emploi
  AND r3.taux_emploi < r2.taux_emploi;
```

R5 — Double critère cadre et salaire

Technique : jointure multi-tables + condition multi-critères avec sous-requête

Cette requête retourne les diplômes cumulant un taux cadre supérieur à 70 % ET un salaire médian supérieur à la médiane nationale toutes disciplines pour une année donnée. Elle met en évidence les formations les plus élitistes.

```
SELECT dp.intitule AS diplome, e.nom AS etablissement,
       d.nom AS discipline,
       r.taux_cadre, r.salaire_median
FROM RESULTAT_IP r
JOIN DIPLOME dp      ON r.id_diplome = dp.id_diplome
JOIN ETABLISSEMENT e ON dp.id_etab   = e.id_etab
JOIN DISCIPLINE d    ON dp.id_disc   = d.id_disc
JOIN ANNEE_ENQUETE a ON r.id_annee   = a.id_annee
WHERE a.annee = ? AND a.delai_mois = 18
  AND r.taux_cadre > 70
  AND r.salaire_median > (
      SELECT AVG(r2.salaire_median)
      FROM RESULTAT_IP r2
      JOIN ANNEE_ENQUETE a2 ON r2.id_annee = a2.id_annee
      WHERE a2.annee = ? AND a2.delai_mois = 18
  )
ORDER BY r.salaire_median DESC;
```

R6 — Régions les mieux insérées

Technique : agrégation + `GROUP BY` région

Cette requête classe les régions par taux d'emploi moyen de leurs formations pour la dernière année d'enquête disponible à 18 mois, permettant d'identifier les disparités territoriales d'insertion.

```
SELECT reg.nom AS region,
       ROUND(AVG(r.taux_emploi), 1) AS taux_emploi_moyen,
       COUNT(DISTINCT dp.id_diplome) AS nb_diplomes,
       ROUND(AVG(r.salaire_median), 0) AS salaire_moyen
FROM REGION reg
JOIN ETABLISSEMENT e ON reg.id_region = e.id_region
JOIN DIPLOME dp      ON e.id_etab     = dp.id_etab
```

```sql
JOIN RESULTAT_IP r   ON dp.id_diplome = r.id_diplome
JOIN ANNEE_ENQUETE a ON r.id_annee    = a.id_annee
WHERE a.annee = (
    SELECT MAX(annee) FROM ANNEE_ENQUETE
    WHERE delai_mois = 18
  )
  AND a.delai_mois = 18
GROUP BY reg.nom
ORDER BY taux_emploi_moyen DESC;
```

R7 — Diplômes sans enquête récente

Technique : `LEFT JOIN` + `IS NULL`

Cette requête identifie les diplômes n'ayant aucune enquête d'insertion enregistrée depuis 3 ans. Elle repose sur un `LEFT JOIN` avec une sous-requête filtrant les enquêtes récentes, puis sélectionne les lignes sans correspondance (`IS NULL`).

```sql
SELECT dp.intitule AS diplome,
       e.nom AS etablissement,
       d.nom AS discipline
FROM DIPLOME dp
JOIN ETABLISSEMENT e ON dp.id_etab  = e.id_etab
JOIN DISCIPLINE d    ON dp.id_disc  = d.id_disc
LEFT JOIN (
    SELECT r.id_diplome
    FROM RESULTAT_IP r
    JOIN ANNEE_ENQUETE a ON r.id_annee = a.id_annee
    WHERE a.annee >= (
        SELECT MAX(annee) - 2 FROM ANNEE_ENQUETE
    )
) recent ON dp.id_diplome = recent.id_diplome
WHERE recent.id_diplome IS NULL
ORDER BY d.nom, dp.intitule;
```

R8 — Gain d'insertion 18 vs 30 mois

Technique : double jointure sur `delai_mois` + calcul d'écart

Cette requête mesure, pour chaque discipline, l'écart de taux d'emploi entre les enquêtes à 18 mois et à 30 mois pour la même année. Un gain élevé signale une discipline dont les diplômés mettent plus de temps à s'insérer, mais finissent bien insérés.

```sql
SELECT d.nom AS discipline,
       ROUND(AVG(r30.taux_emploi), 1) AS taux_30,
       ROUND(AVG(r18.taux_emploi), 1) AS taux_18,
       ROUND(AVG(r30.taux_emploi)
             - AVG(r18.taux_emploi), 1) AS gain
FROM DISCIPLINE d
JOIN DIPLOME dp    ON d.id_disc    = dp.id_disc
JOIN RESULTAT_IP r18  ON dp.id_diplome = r18.id_diplome
JOIN ANNEE_ENQUETE a18 ON r18.id_annee = a18.id_annee
JOIN RESULTAT_IP r30  ON dp.id_diplome = r30.id_diplome
JOIN ANNEE_ENQUETE a30 ON r30.id_annee = a30.id_annee
WHERE a18.delai_mois = 18 AND a30.delai_mois = 30
  AND a18.annee = a30.annee
GROUP BY d.nom
ORDER BY gain DESC;
```

4.5 Synthèse des requêtes

Requête	Technique principale	Résultat attendu
R1	`AVG` + `GROUP BY` + `ORDER BY`	Classement des disciplines par taux cadre
R2	Sous-requête scalaire corrélée	Établissements au-dessus de la moyenne discipline
R3	`GROUP BY` discipline + année	Évolution CDI sur 5 ans
R4	Triple jointure temporelle	Disciplines en déclin 3 ans consécutifs
R5	Jointure + double condition	Formations taux cadre $> 70\,\%$ et salaire $>$ médiane
R6	`GROUP BY` région	Classement régional taux d'emploi
R7	`LEFT JOIN` + `IS NULL`	Diplômes sans enquête depuis 3 ans
R8	Jointure `delai_mois` 18 vs 30	Gain d'insertion par discipline

Table 3 – Synthèse des 8 requêtes SQL obligatoires

5 Interface web PHP

L'interface web constitue la couche de présentation du projet. Elle permet aux utilisateurs de consulter, explorer et comparer les données d'insertion professionnelle stockées dans la base MySQL, à travers un ensemble de pages PHP dynamiques.

5.1 Architecture technique

L'application repose sur une pile WAMP (Windows, Apache, MySQL, PHP) et suit une architecture simple sans framework. Le répertoire du projet contient les fichiers suivants :

`connexion.php`	Connexion PDO à la base de données
`nav.php`	Barre de navigation commune
`index.php`	Tableau de bord national
`formation.php`	Fiche formation comparative
`etablissement.php`	Fiche établissement avec classement interne
`comparaison.php`	Comparaison côte à côte
`stats.php`	Requêtes SQL interactives (R1–R8)
`css/style.css`	Feuille de style CSS

Chaque page PHP inclut le fichier de connexion et la barre de navigation, puis exécute ses propres requêtes SQL avant de générer le HTML correspondant. Il n'y a pas de séparation MVC formelle : chaque fichier combine logique métier et affichage, ce qui reste adapté à la taille du projet.

5.2 Connexion à la base de données

Le fichier `connexion.php` centralise la connexion à MySQL via l'extension PDO de PHP. Il est inclus par toutes les autres pages grâce à `require_once`.

```
$dsn = "mysql:host=127.0.0.1;port=8889;
        dbname=projet_ip;charset=utf8mb4";
$options = [
    PDO::ATTR_ERRMODE => PDO::ERRMODE_EXCEPTION,
    PDO::ATTR_DEFAULT_FETCH_MODE => PDO::FETCH_ASSOC,
    PDO::ATTR_EMULATE_PREPARES   => false,
];
$pdo = new PDO($dsn, $user, $password, $options);
```

Plusieurs choix techniques méritent d'être soulignés :

- **PDO** est utilisé plutôt que `mysqli` pour sa portabilité et son support natif des requêtes préparées.
- **ERRMODE_EXCEPTION** : toute erreur SQL lève une exception PHP, ce qui facilite le débogage en développement.
- **EMULATE_PREPARES = false** : les requêtes préparées sont exécutées nativement par MySQL, offrant une meilleure protection contre les injections SQL.
- **FETCH_ASSOC** : les résultats sont retournés sous forme de tableaux associatifs, simplifiant l'accès aux colonnes par nom.

Ce fichier définit également une fonction utilitaire `fmt_sal()` qui formate les salaires avec séparateur de milliers et symbole euro, ou affiche « N/A » lorsque la valeur est absente.

5.3 Navigation

Le fichier `nav.php` génère une barre de navigation horizontale commune à toutes les pages. L'onglet actif est déterminé dynamiquement grâce à la comparaison du nom du script PHP courant avec chaque lien :

```
<?php $page = basename($_SERVER['PHP_SELF']); ?>
<nav>
    <span class="logo">Observatoire IP</span>
    <a href="index.php"
       class="<?= $page === 'index.php'
              ? 'active' : '' ?>">
        Tableau de bord
    </a>
    <!-- ... liens Formations, Etablissements,
         Comparaison, Requetes SQL ... -->
</nav>
```

La barre est collée en haut de l'écran grâce à la propriété CSS `position: sticky`, et l'onglet actif est mis en surbrillance par une bordure inférieure bleue.

5.4 Tableau de bord — `index.php`

La page d'accueil présente un aperçu synthétique de l'insertion professionnelle à l'échelle nationale. Elle affiche :

1. **6 indicateurs clés** sous forme de cartes : taux d'emploi moyen, taux CDI, taux cadre, salaire médian, nombre de formations suivies et nombre total de répondants. Ces valeurs sont calculées sur la dernière année d'enquête disponible à 18 mois.
2. **Top 5 disciplines** classées par taux d'emploi moyen, avec le salaire médian associé.
3. **Top 5 formations** classées par un indice d'attractivité composite, calculé comme suit :

$$\text{Indice} = 0{,}4 \times \overline{\text{taux_emploi}} + 0{,}2 \times \overline{\text{taux_cdi}} + 0{,}2 \times \overline{\text{taux_cadre}} + 0{,}2 \times \frac{\overline{\text{salaire_median}}}{50}$$

Cet indice pondère les différents indicateurs d'insertion pour produire un classement unique. Le coefficient du salaire est divisé par 50 afin de ramener les valeurs en euros à une échelle comparable aux pourcentages.

5.5 Fiche formation — `formation.php`

Cette page permet de consulter en détail les résultats d'une formation sélectionnée via un menu déroulant. Elle affiche :

— Les **informations générales** de la formation : intitulé, établissement, discipline et région, sous forme de cartes.

— Un **tableau chronologique** présentant pour chaque année et chaque délai d'enquête (18 ou 30 mois) les indicateurs suivants : taux d'emploi, taux CDI, taux cadre, salaire médian et nombre de répondants.

— Une **comparaison à la moyenne de la discipline** : pour chaque indicateur, un badge coloré indique si la formation se situe au-dessus (▲ au-dessus) ou en dessous (▼ en dessous) de la moyenne nationale de sa discipline pour la même année et le même délai.

La moyenne de la discipline est calculée par une requête séparée, puis indexée dans un tableau associatif PHP par clé `annee_delai_mois`, permettant une comparaison efficace ligne par ligne :

```
$moyennes_disc[$m['annee'].'_'.$m['delai_mois']] = $m;
```

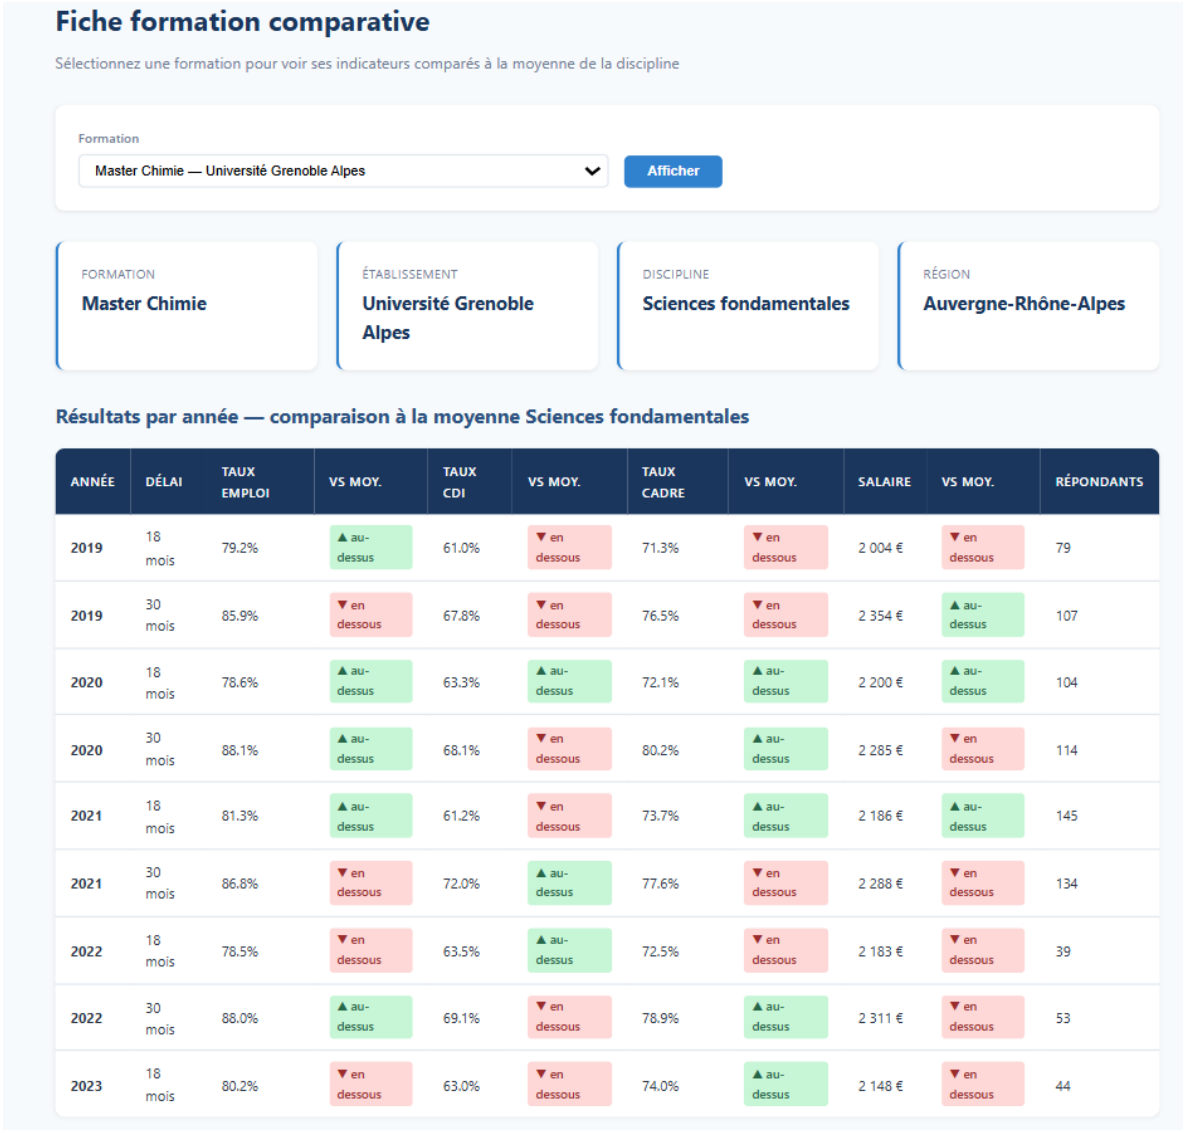
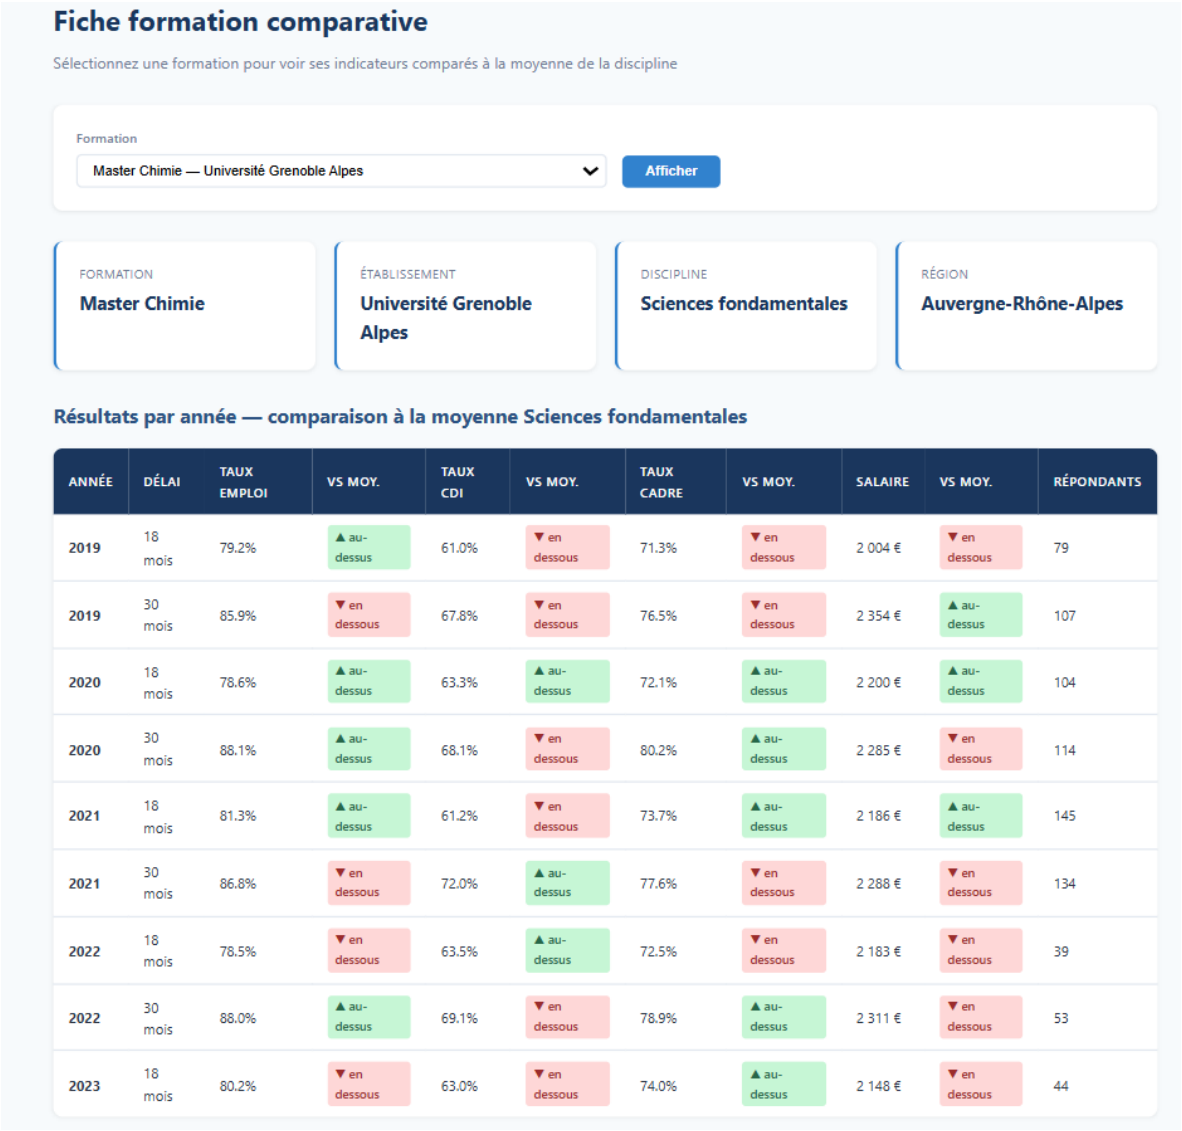


FIGURE 2 – Fiche formation comparative — `formation.php`



ANNÉE	DÉLAI	TAUX EMPLOI	VS MOY.	TAUX CDI	VS MOY.	TAUX CADRE	VS MOY.	SALAIRE	VS MOY.	RÉPONDANTS
2019	18 mois	79.2%	▲ au-dessus	61.0%	▼ en dessous	71.3%	▼ en dessous	2 004 €	▼ en dessous	79
2019	30 mois	85.9%	▼ en dessous	67.8%	▼ en dessous	76.5%	▼ en dessous	2 354 €	▲ au-dessus	107
2020	18 mois	78.6%	▲ au-dessus	63.3%	▲ au-dessus	72.1%	▲ au-dessus	2 200 €	▲ au-dessus	104
2020	30 mois	88.1%	▲ au-dessus	68.1%	▼ en dessous	80.2%	▲ au-dessus	2 285 €	▼ en dessous	114
2021	18 mois	81.3%	▲ au-dessus	61.2%	▼ en dessous	73.7%	▲ au-dessus	2 186 €	▲ au-dessus	145
2021	30 mois	86.8%	▼ en dessous	72.0%	▲ au-dessus	77.6%	▼ en dessous	2 288 €	▼ en dessous	134
2022	18 mois	78.5%	▼ en dessous	63.5%	▲ au-dessus	72.5%	▼ en dessous	2 183 €	▼ en dessous	39
2022	30 mois	88.0%	▲ au-dessus	69.1%	▼ en dessous	78.9%	▲ au-dessus	2 311 €	▼ en dessous	53
2023	18 mois	80.2%	▼ en dessous	63.0%	▼ en dessous	74.0%	▲ au-dessus	2 148 €	▼ en dessous	44

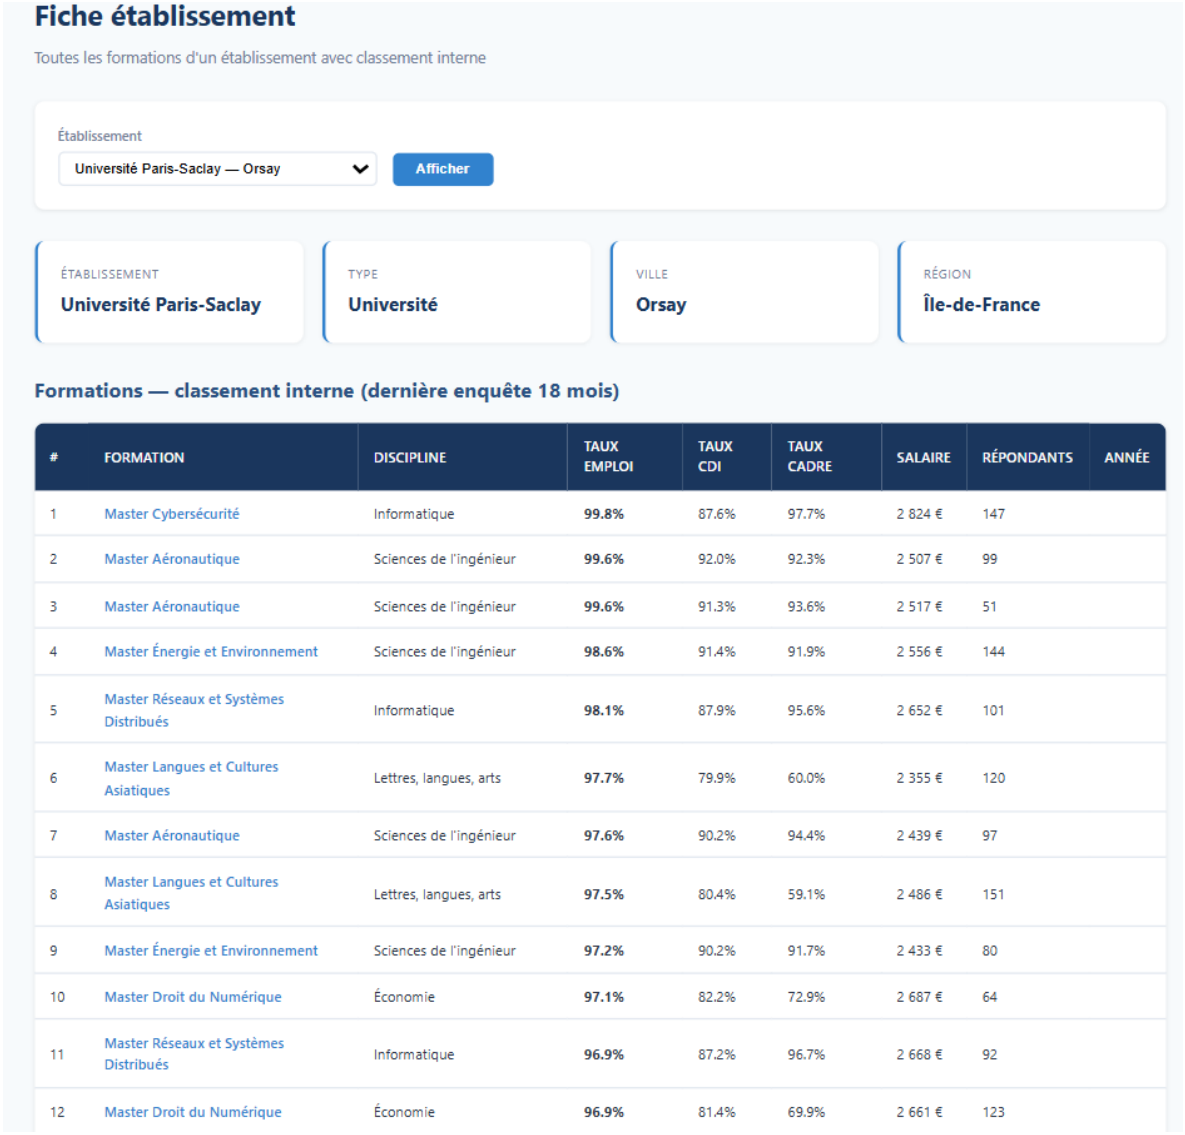
FIGURE 3 – Fiche formation comparative — `formation.php`

5.6 Fiche établissement — `etablissement.php`

Cette page affiche la fiche d'un établissement sélectionné via un menu déroulant. Elle comporte :

- Les **informations générales** : nom, type (université), ville et région, présentées sous forme de cartes.
- Un **classement interne** de toutes les formations de l'établissement, triées par taux d'emploi décroissant pour la dernière enquête à 18 mois. Chaque ligne du tableau affiche l'intitulé (cliquable vers la fiche formation), la discipline, les indicateurs d'insertion et l'année de l'enquête.

La requête utilise un `LEFT JOIN` avec une sous-requête pour récupérer uniquement la dernière année disponible par formation, ce qui permet d'afficher y compris les formations n'ayant pas encore de résultats.



Fiche établissement

Toutes les formations d'un établissement avec classement interne

Établissement

Université Paris-Saclay — Orsay

Afficher

ÉTABLISSEMENT	TYPE	VILLE	RÉGION
Université Paris-Saclay	Université	Orsay	Île-de-France

Formations — classement interne (dernière enquête 18 mois)

#	FORMATION	DISCIPLINE	TAUX EMPLOI	TAUX CDI	TAUX CADRE	SALAIRE	RÉPONDANTS	ANNÉE
1	Master Cybersécurité	Informatique	99.8%	87.6%	97.7%	2 824 €	147	
2	Master Aéronautique	Sciences de l'ingénieur	99.6%	92.0%	92.3%	2 507 €	99	
3	Master Aéronautique	Sciences de l'ingénieur	99.6%	91.3%	93.6%	2 517 €	51	
4	Master Énergie et Environnement	Sciences de l'ingénieur	98.6%	91.4%	91.9%	2 556 €	144	
5	Master Réseaux et Systèmes Distribués	Informatique	98.1%	87.9%	95.6%	2 652 €	101	
6	Master Langues et Cultures Asiatiques	Lettres, langues, arts	97.7%	79.9%	60.0%	2 355 €	120	
7	Master Aéronautique	Sciences de l'ingénieur	97.6%	90.2%	94.4%	2 439 €	97	
8	Master Langues et Cultures Asiatiques	Lettres, langues, arts	97.5%	80.4%	59.1%	2 486 €	151	
9	Master Énergie et Environnement	Sciences de l'ingénieur	97.2%	90.2%	91.7%	2 433 €	80	
10	Master Droit du Numérique	Économie	97.1%	82.2%	72.9%	2 687 €	64	
11	Master Réseaux et Systèmes Distribués	Informatique	96.9%	87.2%	96.7%	2 668 €	92	
12	Master Droit du Numérique	Économie	96.9%	81.4%	69.9%	2 661 €	123	

FIGURE 4 – Fiche établissement avec classement interne — `etablissement.php`

5.7 Comparaison côte à côte — `comparaison.php`

La page de comparaison permet de mettre en regard deux éléments du même type. Un sélecteur de mode propose deux options :

- **Mode formations** : compare deux formations de la base sur l'ensemble des années disponibles (enquêtes à 18 mois).
- **Mode établissements** : compare deux établissements en agrégeant les indicateurs de toutes leurs formations par année.

L'affichage repose sur une grille CSS à deux colonnes (`display: grid; grid-template-columns: 1fr 1fr`). Chaque colonne contient une carte d'identification (nom, détail) et un tableau chronologique des indicateurs, permettant une lecture comparative directe.

```
if ($mode === 'formations') {
    // Requete sur DIPLOME + RESULTAT_IP
} else {
    // Requete agregee sur ETABLISSEMENT
}
```

5.8 Requêtes SQL interactives — `stats.php`

Cette page centralise l'exécution et l'affichage des 8 requêtes SQL obligatoires du projet (R1 à R8). Un formulaire en haut de page permet de sélectionner l'année de référence pour les requêtes paramétrées (R2 et R5).
Chaque requête est présentée dans une section dédiée comprenant :

- Un **titre** identifiant la requête (R1, R2, etc.).
- Une **description** de la technique SQL employée.
- Le **tableau de résultats** généré dynamiquement par PHP.

Les requêtes paramétrées (R2, R5) utilisent des **requêtes préparées** PDO avec `prepare()` et `execute()`, protégeant contre les injections SQL :

```
$stmt = $pdo->prepare("SELECT ... WHERE a.annee = ?
    AND r.salaire_median > (
        SELECT AVG(r2.salaire_median) ...
        WHERE a2.annee = ? ...)");
$stmt->execute([$selected_annee, $selected_annee]);
$r2 = $stmt->fetchAll();
```

Les requêtes sans paramètre (R1, R3, R4, R6, R7, R8) sont exécutées directement via `$pdo->query()`. Les résultats vides sont gérés avec un message « Aucun résultat » affiché dans un `<td>` couvrant toute la largeur du tableau.

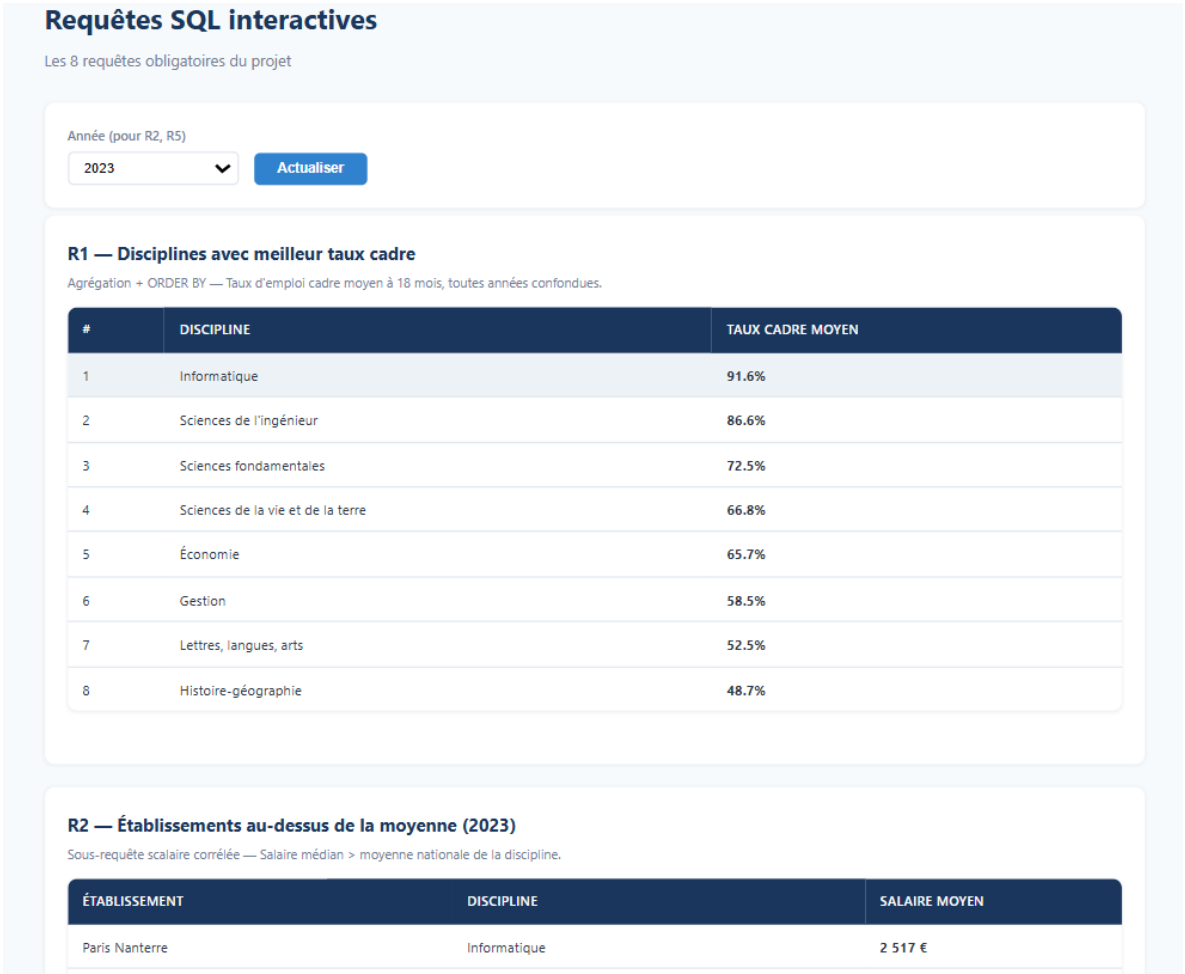


FIGURE 5 – Requêtes SQL interactives — `stats.php`

5.9 Sécurité de l'application

Plusieurs mécanismes protègent l'application contre les vulnérabilités courantes :

- **Injection SQL** : toutes les données provenant de l'utilisateur (paramètres `$_GET`) sont transmises via des requêtes préparées PDO avec des marqueurs `?`. Aucune variable utilisateur n'est concaténée directement dans une requête SQL.
- **XSS (Cross-Site Scripting)** : toutes les données affichées dans le HTML sont échappées avec `htmlspecialchars()`, empêchant l'injection de code JavaScript malveillant.
- **Typage des paramètres** : les identifiants numériques reçus en `GET` sont convertis en entier avec `(int)` avant utilisation, éliminant tout contenu non numérique.

5.10 Design et responsive

La feuille de style `css/style.css` définit un design sobre et professionnel utilisant des variables CSS (`:root`) pour les couleurs principales. Les principaux choix de design sont :

- **Système de cartes** (`.cards`) : grille CSS auto-adaptative (`grid-template-columns: repeat(auto-fit, minmax(220px, 1fr))`) pour les indicateurs chiffrés, avec bordure latérale bleue comme accent visuel.
- **Tableaux stylisés** : en-tête sur fond bleu foncé, survol des lignes en gris clair, coins arrondis et ombre légère.
- **Badges visuels** : les comparaisons (au-dessus / en dessous de la moyenne) sont signalées par des badges colorés en vert ou rouge.
- **Responsive** : une media query `@media (max-width: 768px)` adapte la grille de comparaison en une seule colonne et réorganise la navigation sur mobile.

6 Conclusion

Ce projet nous a permis de couvrir l'ensemble du cycle de développement d'une application de bases de données, depuis le traitement des données brutes jusqu'à la restitution interactive via une interface web.

Le travail de **nettoyage et d'enrichissement du dataset** MESRI a constitué une première étape essentielle. La fusion des colonnes établissement, le remplacement des valeurs masquées par des `NULL` et l'interrogation de l'API du Ministère pour récupérer les données géographiques manquantes ont permis de construire un jeu de données exploitable et cohérent avec le schéma demandé.

La **modélisation** via le MCD et le MLD a abouti à un schéma relationnel en 6 tables normalisé, dont les contraintes d'intégrité (clés étrangères, `CHECK`, `UNIQUE`) garantissent la cohérence des données à l'insertion. Les index ajoutés sur la table `RESULTAT_IP` optimisent les performances des requêtes les plus fréquentes.

Les **8 requêtes SQL** obligatoires mettent en œuvre des techniques variées — agrégations, sous-requêtes corrélées, triple auto-jointure temporelle, `LEFT JOIN` avec détection d'absence — démontrant la capacité du schéma à répondre à des questions analytiques complexes sur l'insertion professionnelle.

Enfin, l'**interface web PHP** offre un accès intuitif aux données à travers cinq pages complémentaires : un tableau de bord national avec indicateurs synthétiques, des fiches formation et établissement avec comparaison aux moyennes, un outil de comparaison côte à côte, et une page dédiée aux requêtes SQL interactives. L'utilisation de requêtes préparées PDO et de `htmlspecialchars()` assure la sécurité de l'application contre les injections SQL et le XSS.

Parmi les **limites** du projet, on peut noter l'absence de graphiques dynamiques (qui pourraient être ajoutés avec une bibliothèque JavaScript comme Chart.js), le manque de pagination pour les tableaux volumineux, et l'absence d'un système d'authentification pour restreindre l'accès aux données. De plus, l'architecture monolithique (un fichier PHP par page, sans séparation MVC) pourrait devenir difficile à maintenir à plus grande échelle.

En termes de **perspectives**, le projet pourrait être étendu par l'intégration de visualisations graphiques pour les évolutions temporelles, l'ajout de filtres avancés (par région, par discipline) sur le tableau de bord, ou encore l'import automatisé de nouvelles données CSV à chaque publication du MESRI. Une migration vers un framework PHP tel que Laravel permettrait également de structurer davantage le code et de faciliter les évolutions futures.